



# Fundamentos Python para IA y Machine Learning

## Lección 4: Modelos de Regresion y Clasificación II

## Indice

Introducción.....	3
Deep Learning.....	4
Concepto y Fundamento.....	4
Abordaje del problema.....	5
Bibliografía.....	6

## **Introducción**

En la presente lección se ha hablado de los modelos de clasificación y como se emplean las redes neuronales para ponerlos en práctica y realizar predicciones mediante los mimos, y durante toda la asignatura se ha mencionado varias veces el Machine Learning y se han dado indicios del Deep Learning. En el presente documento, hablaremos sobre este mismo tema tratando varios aspectos del mismo.

# Deep Learning

## Concepto y Fundamento

Empecemos por definir de la forma mas sencilla posible lo que se entiende por Deep Learning:

*Se conoce como Deep Learning al procedimiento por el cual las redes neuronales artificiales pretenden imitar el funcionamiento del cerebro humanos.*

Partiendo de esta definición es sencillo entender que con la existente tecnología, las redes neuronales están lejos de ser lo que pretenden sin embargo si es cierto que las redes neuronales han traído consigo pecosos y métodos que permiten realizar cálculos y computaciones complejas en tiempos sustancialmente más cortos.

Por tanto, el concepto de Deep Learning nace de intentar imitar el cerebro humano con el fin de que un algoritmo aprenda de grandes cantidades de información para entregar resultados al introducir datos que no ha visto nunca. Este proceso se da gracias a las capas ocultas de las redes neuronales las cuales son el fundamento de este concepto y pueden llegar a ser tremendamente complejas siendo capaces de realizar gran cantidad de cálculos en tiempos reducidos.

## Redes Neuronales Multicapa

En los inicios de las redes neuronales estas constaban unicamente de una capa lo que limitaba enormemente la capacidad de procesamiento de información. Esto se debía mayormente a la limitada capacidad de los ordenadores para asimilar y procesar información, esto ha ido cambiando con los años y a día de hoy poseemos ordenadores capaces de procesar y manipular grandes cantidades de información, esta evolución en la tecnología computacional ha permitido a las redes neuronales evolucionar y hoy en día son lo que llamamos redes neuronales multicapa, el principal pilar de la inteligencia artificial de hoy en día.

Estas redes se diferencian de sus predecesoras por poseer, como su nombre indica, varias capas de procesamiento, esto mismo ha permitido crear redes tan complejas y útiles como las Redes Neuronales Convolucionales, explicadas en el siguiente apartado, o los Auto Encoders, redes neuronales pensadas para aprender como comprimir una imagen de entrada y descomprimirla de nuevo a la imagen original.

En esencia podemos decir que las redes neuronales multicapa son las responsables de que hoy en día podamos generar modelos lo suficientemente complejos para poder seguir investigando el campo de la IA y avanzando hacia elementos cada vez mas complejos.

## Redes neuronales convolucionales

Nacen de la necesidad de otorgar a las maquinas la capacidad de interpretar la información obtenida mediante cámaras de visión artificial. De esto se deduce que necesariamente, estas redes están especializadas en el procesamiento de imágenes y que a raíz de ello han de ser buenas trabajando con grandes cantidades de información.

### ¿Que son?

Para entenderlo, analicemos primero como el cerebro humano interpreta las imágenes que ve a su alrededor, pongamos un ejemplo sencillo para ello:

Cuando se nos muestra una imagen de un rostro, sabemos al instante que estamos viendo esto es debido a que nuestro cerebro es capaz de identificar ciertos elementos como pueden ser los ojos, la boca o la nariz e identifica, por ejemplo, un ojo porque distingue la forma de la pupila, las pestañas y las zonas blancas y todo esto es capaz de diferenciarlo ya que es capaz de identificar los patrones simples, cambios de contraste y texturas.

Todo lo que hace nuestro cerebro para analizar e identificar una imagen a termino práctico, no es mas que un proceso en cascada mediante el que empieza identificando patrones simples y termina identificando los patrones ms complejos sabiendo esto, podríamos traducir esto a algoritmos y obtendríamos una red neuronal convolucional.

### ¿Como funcionan?

Tomando una imagen cualquiera, si la intentáramos tratar con una red neuronal clásica el input introducido sería la imagen por vectores de la forma  $n \times 1$  pixels, siendo  $n$  el alto de la imagen. Esto en realidad para el procesamiento de la imagen nos generaría un problema ya que la posición de cada pixel respecto a los de su entorno no tendría relevancia para nuestra red clásica cuando en realidad cada pixel de una imagen tiene una estrecha relación con sus vecinos entonces, ¿Como funcionan las redes neuronales convolucionales?

Se caracterizan por emplear un modelo matemático llamado convolución que dicho de forma simple consiste en aplicar una serie de transformaciones llamadas kernels o filtros sobre conjuntos de pixels para obtener otra imagen llamada mapa de características.

Estos filtros en realidad son matrices cuadradas de diferentes dimensiones que aplicadas sobre un conjunto de pixels nos retornarán un nuevo pixel que contendrá toda la información de ese grupo que acabamos de analizar. Como ya hemos mencionado dependiendo de los valores de la matriz del filtro, obtendremos un mapa de características u otro, por ejemplo:

0	0	0
0	1	0
0	0	0

Empleando el filtro mostrado, lo que conseguiremos será únicamente copiar la imagen.

$\frac{1}{9}$	$\frac{1}{9}$	$\frac{1}{9}$
$\frac{1}{9}$	$\frac{1}{9}$	$\frac{1}{9}$
$\frac{1}{9}$	$\frac{1}{9}$	$\frac{1}{9}$

Dando el siguiente formato al filtro lo que lograremos será generar un desenfoque generalizado a la imagen

-1	0	1
-1	0	1
-1	0	1

-1	-1	-1
0	0	0
1	1	1

Con los siguientes dos filtros se obtendrá una imagen en la que resaltarán los bordes verticales u horizontales respectivamente.

Dicho esto la siguiente cuestión sería ¿Cómo se definen estos filtros?

No seremos nosotros quienes se encarguen de ello, será la red neuronal mediante entrenamiento la que aprenderá que filtros serán necesarios para detectar unos patrones u otros para poder generar mapas de características cuya información sea relevante.

Sin embargo, seguimos teniendo el problema inicial. Es por esto que las redes neuronales convolucionales están diseñadas con forma de cono es decir, a medida que nos adentramos en la red, tendremos información más sencilla pero más densa dicho de otro modo, las capas serán cada vez más pequeñas pero contendrán más información. Esto se consigue por dos sucesos uno de ellos es el ir reduciendo la cantidad de píxeles de la imagen y el otro suceso, es el hecho de que cada píxel de cada capa, contiene la información de un grupo completo de la capa anterior además de que el output de cada capa es el input de la siguiente. Es por ello que una vez la red neuronal convolucional ha terminado de procesar la imagen no retorna un grupo de outputs que si pueden ser empleados para ser el input de una red neuronal clásica que nos de una predicción o que realice los cálculos que sean necesarios.

## Redes Neuronales Recurrentes

Se caracterizan por ser redes neuronales no necesariamente complejas y que otorgan a los mecanismos que las emplean memoria.

### ¿Que son?

Su nombre nos da una pista de lo que las caracteriza ya que estas redes neuronales funcionan introduciendo en iteraciones mas posteriores a la primera el output de la iteración anterior dando así a la red neuronal la capacidad de aprender literalmente de sus errores y aciertos.

Existen varios tipos de red neuronal recurrente, vemos algunas:

- La SRN

Simple Recurrent Net por sus siglas en ingles son la base del resto de redes neuronales recurrentes y se emplean mayormente en reconocimiento de voz o reconocimiento de escritura a mano alzada.

- La LSTM o Long Short Term Memory

El hecho de emplear como una de las entradas para una iteración los resultados de la anterior radica en el empleo de los algoritmos de retropropagación y de descenso del gradiente para la corrección y entrenamiento de la red pues sucede, con esos elementos, que tienden a crecer enormemente o a desvanecerse a medida que se realizan iteraciones por lo que se generan problemas en la memorización de dependencias a largo plazo. Para resolver esto las LSTM incorporan tres elementos que son:

- La puerta de entrada que controla cuando nueva información nueva en la memoria.
- La puerta de olvido que controla cuando y que parte de la información se desecha dando pie a que la red se quede unicamente con la información mas relevante.
- La puerta de salida que controla cuando se emplea la información en memoria en la celda.

Por la versatilidad que presentan, las redes LSTM se emplean en aplicaciones como compresión de textos de lenguajes naturales, reconocimiento de escritura a mano, reconocimiento de voz, reconocimiento de gestos, captura de imágenes, etc.

- Las GRU o Gradient Recurrent Unit

Mas simples que sus hermanas LSTM, se caracterizan por no tener puerta de salida, ser de rápido entrenamiento o ser mas eficientes en su ejecución constan de:

- Puerta de actualización que controla cuánto del contenido de la iteración anterior hay que mantener.
- Puerta de reajuste que define como se introduce la nueva entrada a la información existente.

Estas redes presentan un rendimiento mejor en conjuntos de datos mas reducidos, sin embargo presentan dificultades el enfrentarse a cantidades mas grandes de datos.



## Bibliografía

- IBM: [¿Qué es el aprendizaje profundo? | IBM](#)
- [YouTube | DotCSV](#)
- Techinfo: [Red neuronal multicapa – Techinfo](#)
- Diegocalvo: [Red Neuronal Recurrente - RNN - Diego Calvo](#)